

Construindo o “R” do RAG: Recuperação Esparsa, Densa e Híbrida de Artigos Científicos sobre Aprendizagem Adaptativa

Felipe Dôza de Andrade¹

¹Faculdade de Computação (FACOM) - Universidade Federal de Mato Grosso do Sul (UFMS) - Campo Grande - MS - Brasil

`felipe.doza@ufms.br`

Abstract. *This paper designs, implements and evaluates the retrieval component (the “R”) of a Retrieval-Augmented Generation pipeline over a collection of 2,500 scientific papers built from the ArXiv API around the author’s research topic (machine learning for adaptive learning and student engagement/dropout prediction). Three retrievers are implemented over the same collection: a sparse lexical one (BM25) and two dense ones based on nearest-neighbour search (TF-IDF and SPECTER embeddings). A hybrid module (M5) fuses sparse and dense rankings via Reciprocal Rank Fusion. Systems are compared on 15 manually annotated test queries (367 relevance judgments) using $P@10$, $R@10$, MAP and $nDCG@10$. The hybrid ranking outperformed every single retriever on all four metrics, improving MAP by 31.6% over the best individual model, which empirically confirms the complementarity between the sparse and dense paradigms.*

Resumo. *Este artigo projeta, implementa e avalia o componente de recuperação (o “R”) de um pipeline de Retrieval-Augmented Generation (RAG) sobre uma coleção de 2.500 artigos científicos construída a partir da API do ArXiv em torno do tema de pesquisa do autor (aprendizado de máquina para aprendizagem adaptativa e previsão de engajamento/evasão estudantil). Implementam-se três recuperadores sobre a mesma coleção: um esparsa e lexical (BM25) e dois densos baseados em busca por vizinhos mais próximos (TF-IDF e embeddings SPECTER). Um módulo híbrido (M5) funde os rankings esparsa e denso por Reciprocal Rank Fusion. Os sistemas são comparados em 15 consultas de teste anotadas manualmente (367 julgamentos de relevância), usando $P@10$, $R@10$, MAP e $nDCG@10$. O ranking híbrido superou todos os recuperadores isolados nas quatro métricas, melhorando o MAP em 31,6% sobre o melhor modelo individual, o que confirma empiricamente a complementaridade entre os paradigmas esparsa e denso.*

1. Introdução

A explosão na produção científica deslocou o gargalo da pesquisa da escrita para a descoberta de trabalhos relevantes. Plataformas como o ArXiv recebem milhares de submissões por mês, e sistemas baseados em *Retrieval-Augmented Generation* (RAG) [Lewis et al. 2020] têm sido propostos para auxiliar pesquisadores a navegar nesse volume. Em um sistema RAG, antes que qualquer modelo generativo entre em cena, é

preciso *recuperar* um pequeno conjunto de documentos potencialmente relevantes para a consulta do usuário, e é esse componente, o “R” do RAG, o objeto deste trabalho [Gao et al. 2024].

O “R” do RAG é, em essência, um problema de aprendizado de máquina sobre texto: ponderação probabilística de termos, busca por vizinhos mais próximos e combinação de modelos podem ser articulados em um sistema funcional que ajuda o pesquisador a encontrar artigos relevantes em uma base científica real. Este trabalho projeta, implementa e avalia esse componente sobre uma coleção construída pelo autor a partir do ArXiv. O sistema recebe uma consulta em texto livre e devolve uma lista ranqueada de artigos, comparando criticamente diferentes estratégias de recuperação.

As contribuições são: (i) a construção e documentação de uma coleção de 2.500 artigos alinhada ao projeto de pesquisa do autor; (ii) a implementação de um recuperador esparsa (BM25) e dois densos (KNN sobre TF-IDF e sobre *embeddings* SPECTER); (iii) um módulo de *ranking* híbrido que funde os paradigmas; e (iv) uma avaliação experimental com 15 consultas e julgamentos de relevância próprios, na qual o híbrido supera todos os *baselines*.

O restante do artigo organiza-se assim: a Seção 2 apresenta o referencial teórico e trabalhos relacionados; a Seção 3 descreve a metodologia (coleta, pré-processamento e modelos); a Seção 4 detalha o protocolo de avaliação; a Seção 5 apresenta e discute os resultados; e a Seção 6 traz as considerações finais.

2. Referencial Teórico e Trabalhos Relacionados

A recuperação esparsa tem no BM25 seu modelo canônico, derivado do arcabouço probabilístico de relevância [Robertson and Zaragoza 2009], cuja fundamentação estatística é detalhada por Manning et al. [Manning et al. 2008]. Tal como o classificador Naïve Bayes, o BM25 modela a relevância como uma probabilidade assumindo independência entre termos, o que estabelece a primeira conexão direta deste trabalho com os tópicos da disciplina.

A recuperação densa ganhou força com modelos de *embeddings*: o *Dense Passage Retrieval* [Karpukhin et al. 2020] para perguntas e respostas, e o SPECTER [Cohan et al. 2020], que aprende representações de documentos científicos a partir de sinais de citação, sendo particularmente adequado a uma coleção de artigos. Uma visão unificada dos paradigmas esparsa, denso e híbrido é proposta por Lin [Lin 2021], referencial direto para o módulo híbrido aqui implementado. Para avaliação, o BEIR [Thakur et al. 2021] consolidou *benchmarks* heterogêneos de Recuperação de Informação; conforme as regras do trabalho, ele não é usado como coleção principal, servindo apenas de inspiração metodológica. O conceito de RAG, que contextualiza o componente de recuperação, foi cunhado por Lewis et al. [Lewis et al. 2020] e sistematizado por Gao et al. [Gao et al. 2024].

3. Metodologia

3.1. Escopo da coleção e relação com o projeto de pesquisa

A coleção reflete o núcleo computacional do projeto de mestrado do autor, que investiga um sistema de gamificação adaptativa baseado em aprendizado de máquina para reduzir o

abandono de tarefas em estudantes da educação profissionalizante. O tema foi traduzido em palavras-chave de coleta como *gamification*, *adaptive/personalized learning*, *learning analytics*, *knowledge tracing*, *student engagement*, *dropout prediction*, *intelligent tutoring systems* e *educational data mining*. A consulta de coleta combinou essas palavras-chave (um grande OR) com as categorias ArXiv `cs.CY`, `cs.HC`, `cs.LG` e `cs.AI`, na janela de 2017 a 2026.

A coleta foi realizada via API pública do ArXiv, com salvamento incremental e remoção de duplicatas por `arxiv_id`, totalizando **2.500 artigos** válidos, cada um com identificador, título, *abstract*, autores, categorias e data. A composição por categoria primária concentra-se no núcleo educação/aprendizado de máquina (Tabela 1), e a distribuição temporal cresce de forma acentuada a partir de 2023, refletindo a recente expansão do aprendizado profundo aplicado à educação. A dupla motivação é obter um recuperador útil para a própria revisão bibliográfica e poder julgar com propriedade a relevância dos resultados na fase de avaliação.

Tabela 1. Composição da coleção por categoria primária do ArXiv (principais).

Categoria	Docs	Categoria	Docs
cs.LG (aprendizado de máquina)	754	cs.CL (ling. computacional)	119
cs.CY (computadores e sociedade)	504	cs.CV (visão computacional)	107
cs.HC (interação humano-comp.)	375	stat.ML (estatística/ML)	58
cs.AI (inteligência artificial)	259	demais categorias	324

3.2. Pré-processamento

Aplica-se o *mesmo pipeline* a documentos e consultas, para garantir o casamento de termos: conversão para minúsculas, remoção de pontuação e dígitos por expressão regular, remoção de *stopwords* do inglês (NLTK) e descarte de *tokens* com menos de três caracteres. O *stemming* de Porter foi mantido como opção desativada por padrão: ele aumenta a cobertura ao aproximar formas flexionadas, mas pode colapsar termos técnicos distintos. Na vetorização TF-IDF adotaram-se `min_df=2`, que descarta termos raríssimos (em geral ruído), e `sublinear_tf`, que amortece termos muito frequentes. A indexação cobre o texto concatenado de título e *abstract*.

3.3. Recuperação esparsa: BM25

O BM25 atribui a cada documento um *score* que cresce com a frequência dos termos da consulta (TF) e com a raridade desses termos no *corpus* (IDF), corrigido pelo tamanho do documento. Adotaram-se os hiperparâmetros $k_1 = 1,5$ (saturação de TF, no meio da faixa usual de 1,2 a 2,0) e $b = 0,75$ (normalização por tamanho, padrão da literatura [Robertson and Zaragoza 2009]). Como os *abstracts* têm tamanho semelhante, a penalização moderada por tamanho é adequada. A implementação usa a biblioteca `rank_bm25`.

3.4. Recuperação densa: KNN sobre TF-IDF e SPECTER

A segunda estratégia aplica a ideia da aula de KNN à recuperação: cada documento e cada consulta tornam-se vetores, e devolvem-se os K documentos mais próximos como *ranking*. A diferença para a classificação é conceitual: em vez de votar uma classe entre os vizinhos, entregam-se os próprios vizinhos como resposta. Usou-se a similaridade do cosseno. Duas representações foram avaliadas:

- **TF-IDF** (*baseline* clássico): vetorização termo-a-termo via `TfidfVectorizer` do *scikit-learn*, conectando ponderação de termos (paradigma estatístico) com busca por vizinhos (KNN).
- **SPECTER** [Cohan et al. 2020]: *embeddings* densos pré-treinados sobre artigos científicos (modelo `allenai-specter` via *sentence-transformers*), que capturam similaridade semântica mesmo sem coincidência exata de termos. Optou-se por esta versão por executar de forma robusta no ambiente disponível; o *embedding* provem da rede neural pré-treinada, estabelecendo a conexão com Redes Neurais.

Em ambos os casos, o cômputo das similaridades e a seleção do top- K foram implementados pelo autor (produto interno sobre vetores L_2 -normalizados), e não delegados a uma biblioteca de RAG.

3.5. Módulo M5: *ranking* híbrido (esparso + denso)

O módulo de aprofundamento escolhido combina BM25 e o recuperador denso SPECTER por *Reciprocal Rank Fusion* (RRF):

$$score_{RRF}(d) = \sum_{s \in \{BM25, \text{denso}\}} \frac{1}{c + rank_s(d)}, \quad c = 60, \quad (1)$$

estratégia que dispensa a normalização de *scores* em escalas diferentes (o BM25 não é limitado; o cosseno vive em $[-1, 1]$). A hipótese é que o lexical favorece consultas com termos exatos e o denso favorece paráfrases e sinônimos, de modo que a fusão recupere relevantes que cada um isoladamente perderia.

4. Avaliação Experimental

Construiu-se manualmente um conjunto de **15 consultas de teste**, cobrindo subáreas distintas do tema (métodos, aplicações, *surveys* e *datasets*) e variando o nível de especificidade. Para cada consulta, formou-se um *pool* com o top-10 de cada um dos quatro sistemas (BM25, TF-IDF, SPECTER e híbrido), e cada documento do *pool* foi anotado como 0 (não relevante), 1 (relevante) ou 2 (altamente relevante). O processo gerou **367 julgamentos de relevância** (132 com grau 2 e 156 com grau 1), com média de 19,2 documentos relevantes por consulta.

O critério de relevância adotado foi: considerou-se *altamente relevante* (2) o artigo cujo título ou *abstract* trata diretamente do problema da consulta como contribuição central; *relevante* (1) o que aborda o tema de forma parcial ou em área vizinha aplicável; e *não relevante* (0) o que apenas compartilha termos isolados sem tratar do assunto.

Reportam-se P@10, R@10, MAP e nDCG@10, calculados pelo *script* de avaliação fornecido pela disciplina. Vale a ressalva metodológica de que, com *qrels* via

pooling, o total de relevantes é uma estimativa (só se conhecem os relevantes que apareceram nos *pools*). Como a média de relevantes por consulta (19,2) excede o tamanho do *ranking* avaliado ($k = 10$), o $R@10$ fica limitado a um teto teórico de aproximadamente 0,57, o que deve ser considerado na leitura dessa métrica.

5. Resultados e Discussão

A Tabela 2 apresenta as médias das métricas por sistema. O **ranking híbrido (M5) superou todos os recuperadores isolados nas quatro métricas**. O ganho mais expressivo ocorreu no MAP: 0,7228 contra 0,5492 do melhor isolado (TF-IDF), uma melhora de **31,6%**. Como o MAP premia rankings que colocam os relevantes mais ao topo, esse resultado evidencia que a fusão não apenas recupera os documentos certos, mas também os ordena melhor.

Tabela 2. Médias das métricas por sistema sobre as 15 consultas de teste.

Sistema	P@10	R@10	MAP	nDCG@10
BM25 (esparso)	0,760	0,410	0,521	0,690
KNN TF-IDF (denso)	0,793	0,429	0,549	0,696
KNN SPECTER (denso)	0,827	0,425	0,530	0,633
Híbrido RRF (M5)	0,860	0,449	0,723	0,742

Esparso vs. denso: onde cada um vence. A análise por consulta revela uma divisão clara de competências. O BM25 é superior em consultas de termo exato e jargão: alcançou $P@10 = 1,0$ em “*student dropout prediction*” (q1), “*knowledge tracing*” (q2) e “*educational data mining*” (q6). Foi também o único a se sair bem em “*reinforcement learning for adaptive learning paths*” (q3, $P@10 = 0,6$), onde os modelos densos colapsaram (SPECTER, $P@10 = 0,1$): por proximidade semântica, o SPECTER derivou para artigos de aprendizado por reforço genérico, afastando-se do contexto educacional. Já o SPECTER venceu em consultas de paráfrase e sinônimo: em “*affective computing for student emotion detection*” (q14) obteve $P@10 = 1,0$ e $MAP = 0,85$, contra 0,60 e 0,35 do BM25, pois reconheceu a proximidade entre “*affective*” e “*emotion*” sem depender de coincidência lexical.

O papel da fusão. Na maioria das consultas, o híbrido combinou as forças dos dois paradigmas: em “*detecting disengagement*” (q8) o MAP saltou para 0,97; em q11 foi de $\approx 0,58$ para 0,82; e em “*self-supervised representation learning*” (q12) o $P@10$ subiu de 0,3-0,4 para 0,7. Há, no entanto, um caso instrutivo de falha: em q3, como o componente denso colapsou ($MAP = 0,02$), o RRF foi arrastado e ficou *pior* que o BM25 isolado. Isso evidencia uma limitação importante do RRF: ele não é robusto quando um dos componentes é catastroficamente ruim para uma consulta específica.

Conexão com a disciplina. A Tabela 3 sintetiza as relações entre os componentes do sistema e os tópicos vistos em sala, reforçando que o “R” do RAG é, na prática, uma articulação de técnicas de aprendizado de máquina sobre texto.

Tabela 3. Mapeamento entre componentes do sistema e tópicos da disciplina.

Componente	Tópico da disciplina
BM25 / TF-IDF	Naïve Bayes e paradigmas estatísticos
KNN sobre vetores	Classificador KNN (vizinhos mais próximos)
<i>Embeddings</i> SPECTER	Redes Neurais e <i>Backpropagation</i>
<i>Ranking</i> híbrido (M5)	Combinação de modelos

Limitações. Além do teto de R@10 imposto pelo *pooling* (já discutido), o conjunto de 15 consultas e a anotação por um único avaliador limitam a generalização. A estimativa de *recall* via *pool* é um limite superior otimista, pois relevantes fora dos *pools* permanecem desconhecidos.

6. Considerações Finais

Este trabalho implementou e comparou recuperadores esparsos (BM25), densos (TF-IDF e SPECTER) e híbrido (RRF) sobre uma coleção científica própria de 2.500 artigos, alinhada ao projeto de pesquisa do autor. A principal lição é a complementaridade dos paradigmas: o lexical domina consultas de termo exato, o denso domina paráfrases e sinônimos, e a fusão híbrida, vencedora nas quatro métricas e com ganho de 31,6% em MAP, capitaliza essa complementaridade, ainda que sem robustez quando um componente falha gravemente. Como trabalho futuro, o recuperador pode evoluir para alimentar o componente generativo de um RAG voltado à revisão bibliográfica da dissertação do autor, e a fusão pode ser refinada com ponderação adaptativa por consulta. O vídeo de apresentação está disponível em <https://youtu.be/SPoxzb4csHg>.

Declaração sobre uso de Inteligência Artificial

O autor utilizou ferramenta de IA generativa como apoio à estruturação do código dos recuperadores, à organização textual deste relatório e à revisão de redação. As decisões de modelagem, a anotação dos julgamentos de relevância e a análise dos resultados foram conduzidas e revisadas criticamente pelo autor, que se responsabiliza integralmente pelo conteúdo.

Referências

- Cohan, A., Feldman, S., Beltagy, I., Downey, D., and Weld, D. S. (2020). SPECTER: Document-level representation learning using citation-informed transformers. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*.
- Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., and Wang, H. (2024). Retrieval-augmented generation for large language models: A survey. *arXiv preprint arXiv:2312.10997*.

- Karpukhin, V., Oğuz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., and Yih, W.-t. (2020). Dense passage retrieval for open-domain question answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., and Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*.
- Lin, J. (2021). A proposed conceptual framework for a representational approach to information retrieval. *SIGIR Forum*, 55(2).
- Manning, C. D., Raghavan, P., and Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press.
- Robertson, S. and Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389.
- Thakur, N., Reimers, N., Rücklé, A., Srivastava, A., and Gurevych, I. (2021). BEIR: A heterogeneous benchmark for zero-shot evaluation of information retrieval models. In *Proceedings of the Neural Information Processing Systems (NeurIPS) Datasets and Benchmarks Track*.